

82514 · MECATRÓNICA Y ROBÓTICA

Bloque 6

Percepción robótica: visión, estimación de estado y SLAM

Sesiones S25–S31 · 10 horas

6, 11, 12, 13, 18, 19 y 20 de noviembre de 2026 · IQS Universitat Ramon Llull

Hoja de ruta del bloque

1

S25 • vie 6 nov • 2 h , EXAMEN PARCIAL 1 (bloques 1-4): test y problemas

2

S26 • mié 11 nov • 1 h , Formación de imagen y modelo de cámara • calibración en cuaderno guiado

3

S27 • jue 12 nov • 1 h , Procesado clásico y aprendido: el criterio del ingeniero

4

S28 • vie 13 nov • 2 h , Filtro de Bayes, filtro de Kalman y EKF

5

S29 • mié 18 nov • 1 h , Localización con EKF sobre mapa de balizas

6

S30 • jue 19 nov • 1 h , Filtro de partículas y localización de Montecarlo

7

S31 • vie 20 nov • 2 h , SLAM: EKF-SLAM, GraphSLAM, FastSLAM y SLAM visual



S25

Examen parcial 1

Bloques 1-4 · test y tres problemas · 2 horas

Parcial 1: estructura y reglas

A

Test (2,0 pt)

10 preguntas ABCD sobre B1-B4; cada error resta un tercio; en blanco no puntúa

B

Diseño mecatrónico e instrumentación (2,0 pt)

Nyquist y aliasing con cálculo • MDQ: cálculo e interpretación

C

Cinemática directa (3,0 pt)

FK del 2R con números • tabla DH • espacio de trabajo alcanzable

D

IK, jacobiano y estática (3,0 pt)

Las dos ramas de la IK • det J y singularidades • pares con $\tau = J^T \cdot F$


Material: calculadora no programable y una hoja A4 de formulario manuscrito por las dos caras. Seis versiones (A-F) en damero. Los errores de arrastre no se penalizan dos veces.

S26

Formación de imagen y calibración exprés

Cámara estenopeica · proyección · intrínsecos y extrínsecos · calibración como cuaderno guiado


► [Abrir en Colab](#) · [cuaderno S25 imagen y calibración](#)



Cámara estéreo: recuperar la profundidad perdida

La cámara, de Mozi al modelo matricial

El modelo estenopeico: cada punto 3D cae por su rayo — la profundidad se pierde



El modelo estenopeico: la profundidad se pierde en la proyección



Dibujo técnico hecho con cámara oscura (Verbruggen, s. XVIII)

De la escena 3D a la imagen 2D

La cámara estenopeica: el modelo mínimo

- Un punto del mundo, el centro óptico y su proyección en el plano imagen están alineados: la geometría se reduce a triángulos semejantes.
- Las coordenadas de imagen resultan de dividir por la profundidad, esa división es la fuente de todo lo demás:
- Consecuencia central: la proyección pierde la profundidad. Un punto de la imagen corresponde a un rayo completo del espacio, no a un punto.
- Recuperar 3D exige información añadida: estéreo, movimiento, un sensor de profundidad o un modelo del objeto.

$$u = f \frac{X}{Z}, \quad v = f \frac{Y}{Z}$$

Ambigüedad de la perspectiva

Objetos de tamaño y distancia distintos producen la misma imagen: la escala es indeterminable a partir de una vista.

Es el mismo problema que la visión biológica resuelve con dos ojos y que la robótica resuelve con estéreo, estructura desde el movimiento o LiDAR.

En el bloque 7 esa profundidad reaparece convertida en mapa de ocupación.

Modelo matricial y calibración

Parámetros intrínsecos (K)

Distancias focales en píxeles, punto principal y factor de sesgo. Describen la cámara: no cambian al moverla.

Parámetros extrínsecos (R, t)

Rotación y traslación del marco de la cámara respecto al mundo. Describen dónde está: cambian en cada instante y los estima la localización.

Distorsión de lente

El modelo estenopeico ideal no captura la lente real: coeficientes radiales y tangenciales corrigen la curvatura de las rectas hacia los bordes.

Calibración: cuaderno guiado en casa

Tablero de ajedrez, 15-20 vistas variadas, `findChessboardCorners` y `calibrateCamera` en OpenCV.

Entrega en el campus antes de S28; criterio de calidad: error de reproyección por debajo de un píxel. Los resultados se comentan al abrir S28.

S27

Procesado clásico y aprendido

Convolución y bordes · regiones y puntos · rasgos aprendidos · el criterio del ingeniero

- ▶ [Abrir en Colab · cuaderno S26 procesado clásico](#)
- ▶ [Abrir en Colab · cuaderno S27 percepción aprendida](#)

Cuatro herramientas clásicas que siguen vigentes

1

Convolución

Una ventana recorre la imagen combinando vecindarios: suavizado gaussiano, realce, derivadas. Es la operación base, y la misma que ejecuta cada capa convolucional de la sesión siguiente.

2

Bordes

El gradiente marca discontinuidades de intensidad. Canny añade supresión no máxima e histéresis. Aviso: «los bordes de la imagen no son necesariamente los mismos que los bordes de los objetos» (Corke, 2023, p. 454).

3

Regiones

Umbralizado y etiquetado de componentes conexas producen blobs con área, centroide y momentos: base de la inspección industrial por visión.

4

Puntos

Esquinas y descriptores invariantes permiten emparejar la misma escena entre vistas: es la materia prima del SLAM visual de S31.

De rasgos diseñados a rasgos aprendidos

El cambio de paradigma

- Durante décadas el ingeniero diseñaba el descriptor; hoy la red lo aprende de los datos. Corke lo dice sin rodeos: estas técnicas «han sido eclipsadas por las basadas en aprendizaje profundo» (Corke, 2023, p. 510).
- Detección: una sola pasada de red produce cajas, clases y confianzas, la familia YOLO como estándar práctico en tiempo real.
- Segmentación semántica: una etiqueta por píxel. De instancias: además separa objetos individuales del mismo tipo.
- Modelos fundacionales de segmentación (SAM y sucesores): segmentan objetos no vistos en entrenamiento a partir de una indicación.

Coste oculto

Los datos, no el modelo, son el cuello de botella: etiquetar es caro y el dominio de entrenamiento condiciona el resultado.

Una red entrenada con imágenes de día falla de noche; una entrenada en simulación falla en la planta.

Es el mismo problema sim-to-real que veremos en el bloque 8.

Cuándo clásico y cuándo aprendido

Elegir clásico

- Escena controlada: iluminación fija, fondo conocido, pieza siempre igual
- Se exige determinismo y explicabilidad (auditoría, certificación)
- Latencia mínima en hardware modesto, sin GPU
- No hay datos etiquetados ni presupuesto para generarlos
- Medición metrológica: dimensiones, posición subpíxel

Elegir aprendido

- Variabilidad alta: objetos deformables, iluminación cambiante, desorden
- La tarea es de reconocimiento semántico, no de medida
- Existen datos, o un modelo preentrenado que se ajusta con pocos ejemplos
- Se acepta un comportamiento estadístico con tasa de error medida
- Hay cómputo suficiente en el robot o en el borde




S28

Bayes, Kalman y EKF


Creencia · predicción y corrección · linealización

► [Abrir en Colab](#) · [cuaderno S28](#)

Estimar: la curva y la nube



Filtro de Kalman 1D: estimación $\pm 2\sigma$ frente a la medida cruda (S28)



El filtro de Bayes: creencia recursiva

La creencia

El robot no conoce su estado: mantiene una distribución de probabilidad sobre él (la creencia), condicionada a todas las medidas y controles pasados (Thrun et al., 2005, pp. 26-28).

Las dos hipótesis de Markov

El estado siguiente depende solo del actual y del control; la medida depende solo del estado actual. Sin ellas no hay recursión (Thrun et al., 2005, pp. 28-33).

1 Predicción

Propagar la creencia con el modelo de movimiento y el control: la incertidumbre crece

2 Corrección

Ponderar por la verosimilitud de la medida observada: la incertidumbre se reduce

3 Normalización

Escalar para que la creencia vuelva a ser una distribución de probabilidad

Kalman y su extensión no lineal

Filtro de Kalman: el caso gaussiano lineal

- Si el sistema es lineal, el ruido gaussiano y la creencia inicial gaussiana, la creencia se mantiene gaussiana para siempre: basta propagar media y covarianza (Thrun et al., 2005, pp. 40-42).
- La ganancia de Kalman arbitra entre predicción y medida: mucha confianza en el sensor la acerca a la medida; poca, a la predicción.
- El problema: casi ningún robot es lineal. Un vehículo que gira no lo es.
- EKF: linealizar en torno a la estimación actual mediante jacobianas, y aplicar las mismas ecuaciones (Thrun et al., 2005, pp. 54-56).

Precio de linealizar

La linealización es una aproximación: si la no linealidad es fuerte o la incertidumbre grande, la gaussiana deja de describir la creencia real.

El EKF puede divergir y no avisa.

De ahí el filtro de partículas de S30: sin hipótesis gaussiana, a cambio de coste.

S29

Localización con EKF

Taxonomía del problema · modelo de movimiento · modelo de observación

► [Abrir en Colab](#) · [cuaderno S29](#)

Localizar: taxonomía y los dos modelos

1

Seguimiento

La pose inicial se conoce; solo hay que corregir la deriva. El EKF basta

2

Global

La pose inicial se desconoce: la creencia puede ser multimodal

3

Secuestro

El robot es desplazado sin avisar: el filtro debe recuperarse de una creencia errónea

Modelo de movimiento

Predice la pose a partir del control u odometría, con su ruido. Thrun distingue el modelo de velocidad del basado en odometría, en general más preciso en robots con encoders (Thrun et al., 2005, cap. 5).

Modelo de observación

Predice qué mediría el sensor desde una pose dada. Para telémetros, el modelo de haz combina medida correcta, objetos inesperados, fallos y ruido aleatorio (Thrun et al., 2005, p. 153 y ss.).



S30

Filtro de partículas y MCL

Muestreo · pesos · remuestreo · robustez

► [Abrir en Colab](#) · [cuaderno S30](#)

Representar la creencia con muestras

1

Muestrear

Cada partícula se propaga con el modelo de movimiento y su ruido

2

Pesar

Cada partícula recibe un peso proporcional a la verosimilitud de la medida desde su pose

3

Remuestrear

Se sortean partículas con probabilidad proporcional al peso: sobreviven las coherentes

Qué gana

No exige gaussianidad ni linealidad: representa creencias multimodales, resuelve la localización global y, con las variantes adecuadas, el secuestro.

Qué cuesta


El número de partículas gobierna precisión y coste. Con pocas, el filtro puede empobrecerse y descartar la hipótesis correcta; AMCL adapta ese número en marcha, y es el localizador de Nav2 en el bloque 7.

S31

SLAM: del EKF a los grafos

Online y completo · EKF-SLAM · GraphSLAM · FastSLAM · SLAM visual

► [Abrir en Colab](#) · [cuaderno S31](#)



Nube de puntos LiDAR: la materia prima del mapa

El problema circular del SLAM

Mapear y localizarse a la vez

- Para construir el mapa hace falta saber dónde está el robot; para saber dónde está hace falta el mapa. SLAM resuelve ambos simultáneamente (Thrun et al., 2005, cap. 10).
- SLAM online: estima la pose actual y el mapa. SLAM completo: estima toda la trayectoria y el mapa (Thrun et al., 2005, p. 309 y ss.).
- El problema de correspondencia, ¿es este el punto de referencia que ya vi?, es la fuente principal de fallo catastrófico.
- El cierre de bucle reconoce un lugar ya visitado y corrige de golpe la deriva acumulada de toda la trayectoria.

EKF-SLAM

El vector de estado incluye la pose y todos los puntos de referencia; la covarianza los correlaciona.

Esa correlación es lo que hace funcionar el cierre de bucle: corregir la pose corrige todo el mapa.

Su límite es el coste: la covarianza crece con el cuadrado del número de puntos.

GraphSLAM, FastSLAM y el panorama actual

1

GraphSLAM

La trayectoria y las medidas forman un grafo: nodos son poses y puntos, aristas son restricciones blandas. Resolver el SLAM es minimizar el error de todas las restricciones (Thrun et al., 2005, cap. 11). Es el enfoque dominante en sistemas reales.

2

FastSLAM

Factoriza el problema con un filtro de partículas para la trayectoria y filtros independientes por punto de referencia: escala a mapas grandes (Thrun et al., 2005, cap. 13, pp. 437-439).

3

Mapas de ocupación

Con la pose ya conocida, el mapeo se reduce a acumular evidencia por celda en log-odds (Thrun et al., 2005, pp. 281-286). Es el mapa que consumirá Nav2 en el bloque 7.

4

SLAM visual y neuronal

Cámaras en lugar de LiDAR; y una frontera de investigación activa donde el mapa es una representación aprendida (NeRF, neuronal; 3D Gaussian Splatting, de primitivas explícitas) en vez de una nube de puntos.