



82514 • MECATRÓNICA Y ROBÓTICA

Bloque 8

Robótica basada en aprendizaje y seminario de artículos

Sesiones S38-S42 • 6 horas

9, 10, 11, 16 y 17 de diciembre de 2026 • IQS Universitat Ramon Llull

Hoja de ruta del bloque

1

S38 • mié 9 dic • 1 h , Aprendizaje por refuerzo: MDP y Q-learning

2

S39 • jue 10 dic • 1 h , RL profundo, imitación y modelos VLA • sim-to-real

3

S40 • vie 11 dic • 2 h , EXAMEN PARCIAL 2 (bloques 5-7)

4

S41 • mié 16 dic • 1 h , Seminario de artículos científicos I

5

S42 • jue 17 dic • 1 h , Seminario de artículos científicos II y cierre

S38

Aprendizaje por refuerzo: MDP y Q-learning


Interacción y recompensa · política y valor · aprendizaje sin modelo

► [Abrir en Colab](#) · [cuaderno S38](#)




Decisión secuencial: un brazo industrial juega al ajedrez

Manipular y decidir



Banco de manipulación diestra (NIST): el problema que motiva el bloque



La política óptima del gridworld de S38: flechas que rodean el peligro

El marco: decisión secuencial bajo incertidumbre

1 Estado

Lo que el agente observa del mundo en cada instante

2 Acción

Lo que puede hacer desde ese estado

3 Transición

Cómo evoluciona el mundo: puede ser estocástica

4 Recompensa

La señal escalar que define qué es «bien». Diseñarla es la parte difícil

5 Descuento

Cuánto pesa el futuro frente al presente

Lo distintivo del RL


Sutton y Barto señalan dos rasgos propios: la búsqueda por ensayo y error, y la recompensa retardada, la acción buena de ahora puede pagarse mucho después (2018, cap. 1).

El dilema permanente

Explorar acciones nuevas frente a explotar lo que ya funciona. La estrategia epsilon-greedy es la respuesta mínima y la que usaremos en el ejemplo (Sutton y Barto, 2018, cap. 2).

El valor se propaga desde la meta

Iteración de valor: el valor se propaga desde la meta (barrido 0)



Iteración de valor, barrido a barrido: el valor fluye hacia atrás desde la meta

Q-learning: aprender el valor de actuar

De valor a política

- La función $Q(s,a)$ estima el retorno esperado de tomar la acción a en el estado s y actuar bien después. Si se conoce Q , la política óptima es elegir la acción de mayor Q .
- Q-learning aprende Q sin modelo del mundo: solo con transiciones observadas (s, a, r, s'). La actualización:
- El corchete es el error de diferencia temporal: la sorpresa entre lo que esperaba y lo que la experiencia dice ahora (Sutton y Barto, 2018, cap. 6).

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

El muro de la tabla

Q-learning tabular exige una entrada por cada par estado-acción.

Un brazo de 6 ejes con estados continuos no cabe en ninguna tabla, y estados nunca visitados no aportan nada.

La solución, aproximar Q o la política con una red, es la sesión siguiente.

S39

RL profundo, imitación y VLA

PPO y sim-to-real · behavior cloning y diffusion policies · modelos fundacionales

- ▶ [Abrir en Colab · cuaderno S39 RL profundo](#)
- ▶ [Abrir en Colab · cuaderno S40 imitación y VLA](#)

De la tabla a la red, y de la simulación al robot

Política parametrizada

Una red sustituye a la tabla: recibe la observación y produce la acción. Generaliza a estados nunca vistos, a cambio de perder las garantías teóricas del caso tabular (Sutton y Barto, 2018, cap. 13).

PPO

El algoritmo de referencia en robótica: mejora la política limitando cuánto puede cambiar en cada paso, mediante un recorte que evita saltos destructivos (Schulman et al., 2017, arXiv:1707.06347).

Tolera hiperparámetros razonables sin ajuste fino: por eso se impuso.

Por qué en simulación

PPO necesita millones de interacciones. En un robot real serían años y varios robots rotos; en simulación paralela masiva (MuJoCo, Isaac Lab), horas.

La brecha de realidad

Lo aprendido en simulación falla en el robot: fricción, retardos y ruido no modelados. La aleatorización de dominio entrena bajo parámetros variables para forzar políticas robustas (Tobin et al., 2017, arXiv:1703.06907; OpenAI, 2019, arXiv:1910.07113).

Aprender de demostraciones

Behavior cloning: el enfoque directo

- Un humano teleopera el robot; la red aprende a reproducir la acción demostrada dada la observación. Es aprendizaje supervisado sobre pares observación-acción.
- Ventaja decisiva sobre el RL: no hace falta diseñar recompensa ni explorar millones de veces.
- Su fallo característico: al desviarse ligeramente entra en estados no demostrados y el error se acumula.
- Diffusion policies: en lugar de predecir una acción, generan secuencias de acciones por un proceso de difusión, lo que maneja mejor la multimodalidad (Chi et al., 2023, arXiv:2303.04137).

Por qué importa la multimodalidad

Ante un obstáculo, esquivar por la izquierda o por la derecha son ambas correctas.

Una red que predice la acción promedio elige el centro: choca.

Generar la distribución completa de acciones, y no su media, resuelve el problema.

Modelos visión-lenguaje-acción

1 RT-2

Demuestra que un modelo visión-lenguaje entrenado con datos web transfiere conocimiento al control robótico (Google DeepMind, 2023, arXiv:2307.15818)

2 OpenVLA

Abre la receta completa: 7B de parámetros y pesos publicados, lo que permite reproducir y ajustar (Kim et al., 2024, arXiv:2406.09246)

3 $\pi 0$

Modelo de flujo visión-lenguaje-acción para control general de robots, de Physical Intelligence (Black et al., 2024, arXiv:2410.24164)

4 GR00T N1

Modelo fundacional abierto para robots humanoides generalistas (NVIDIA, 2025, arXiv:2503.14734). Gemini Robotics lleva la familia Gemini al control físico (Google DeepMind, 2025)

El patrón común: una arquitectura preentrenada con datos de internet, ajustada con demostraciones robóticas, que acepta instrucciones en lenguaje natural y produce acciones motoras.

Gemelos digitales y síntesis del bloque

Gemelo digital

Una réplica virtual de la célula o la planta, sincronizada con datos reales, sobre la que se simula, se valida y se entrena antes de tocar el sistema físico.

En robótica cierra el círculo: es el mismo simulador de S39 puesto al servicio de la ingeniería de fabricación.

Eco del bloque 1

Es la evolución de diseño de De Silva llevada a su consecuencia: un modelo del sistema real que se monitoriza, se optimiza y devuelve mejoras al sistema (De Silva et al., 2016, p. 8).

La idea tenía diez años; hoy tiene herramientas.

Dónde encaja el aprendizaje en el temario clásico

El aprendizaje no sustituye a la cinemática, al control ni a la estimación: se apoya en ellos. Un VLA decide qué hacer; la cinemática del bloque 4 y los lazos del bloque 5 lo ejecutan; la percepción del bloque 6 le da los ojos; ROS 2 del bloque 7 lo conecta con el hardware. El ingeniero valioso en 2026 es el que entiende ambas mitades y sabe cuándo cada una aporta valor.



S40

Examen parcial 2

Bloques 5-7 · test y tres problemas · 2 horas

Parcial 2: estructura y reglas

A

Test (2,0 pt)

10 preguntas ABCD sobre B5-B7; cada error resta un tercio; en blanco no puntúa

B

Control de una articulación (3,0 pt)

Diseño PD para ζ y ω_n • sobreoscilación • error estacionario con gravedad • windup

C

Estimación (2,5 pt)

Un paso completo de filtro de Kalman 1D • lectura de la ganancia • EKF frente a MCL

D

Planificación y ROS 2 (2,5 pt)

A* sobre rejilla con heurística Manhattan • admisibilidad • diagnóstico de QoS

Material: calculadora no programable y una hoja A4 de formulario manuscrito por las dos caras. El planteamiento vale el 40 % de cada apartado; un resultado sin desarrollo no puntúa.



Seminario de artículos científicos

16 y 17 de diciembre · presentaciones por parejas y cierre del semestre

Cómo se desarrollan las dos sesiones

Formato

Parejas. 7 minutos de exposición y 3 de preguntas, cronometrados en pantalla.

Orden publicado la víspera. Cinco parejas por sesión.

Toda entrega es defendible oralmente y de forma individual.

Qué debe cubrir cada presentación

Problema • método • resultados • limitaciones • conexión explícita con al menos un bloque del curso.

La última es obligatoria: es lo que convierte el seminario en parte de la asignatura y no en un añadido.

Preguntas comodín del profesor

Si el público no pregunta, el profesor dispone de una batería preparada: ¿cuál es la línea base con la que se comparan y es justa? ¿Qué pasaría con este método en el robot del laboratorio? ¿Qué limitación reconocen los autores y cuál se les ha escapado? ¿Qué bloque del curso hace falta dominar para implementar esto? Estas preguntas también modelan qué se espera del público en la sesión siguiente.

Rúbrica de evaluación

40%

Comprensión técnica

¿Entienden el método o repiten el resumen? Se comprueba en las preguntas, no en las diapositivas

30%

Claridad

Estructura, ritmo, calidad de las figuras y capacidad de hacer accesible lo complejo

20%

Análisis crítico

Limitaciones reconocidas y no reconocidas, honestidad de la comparación, aplicabilidad real

10%

Gestión de preguntas

Responder lo que se sabe, admitir lo que no y razonar en voz alta



S43

Defensas del proyecto y cierre

18 de diciembre · 2 h · defensas, repaso del examen y síntesis del semestre



La defensa: qué se evalúa y con qué peso

40%

Integración técnica

¿Los módulos hablan entre sí, hay un sistema, o cuatro prácticas juntas? Es la competencia RAM23-S de la guía docente

25%

Resultados medidos

Al menos una métrica: error de seguimiento, tiempo de ciclo, tasa de éxito en N intentos, error de localización

20%

Análisis crítico

Limitaciones reconocidas, diagnóstico de lo que falló y camino propuesto

15%

Claridad y reparto

Exposición ordenada y participación real de todos los miembros: la defensa es individual

Criterio que se dice en voz alta antes de empezar: un proyecto que no funcionó del todo, pero cuyo equipo sabe por qué, lo ha medido y propone un camino, puntúa por encima de uno que funciona sin explicación.

Repaso del examen: qué entra de forma literal

B1

Definición de mecatrónica y los ocho componentes de un sistema mecatrónico

B2

Las dos partes de la ISO 10218 y los cuatro métodos de operación colaborativa

B3

Características estáticas de un sensor y criterios de selección de actuador

B4

Cinemática directa e inversa, jacobiano y singularidades

B5

Modelado de un lazo, respuesta temporal y sintonía

B6

Filtro de Bayes, ciclo predicción-corrección y formulación del SLAM

B7

Grafo de computación de ROS 2, A* y familias de planificadores

B8

MDP, actualización de Q-learning y qué es un modelo VLA

No se pregunta de forma literal: manipular la ecuación del MDP, derivar las ecuaciones del EKF ni reproducir la arquitectura interna de un VLA. Examen de muestra con solución comentada, publicado hoy en el campus.